


基于多智能体协作的复杂任务求解系统 - 中期报告

1. 系统概要设计

1.1 系统架构实现



1.2 关键模块实现

1.2.1 智能体角色定义

```
# 初始化多模型客户端
from transformers import pipeline

# 1. Planner: Phi-3 (轻量级任务分解)
phi3_config_list = [
    {
        "model": "phi3:mini", # 确保模型名称与 ollama 中的名称匹配
        "api_type": "ollama",
        "client_host": "http://localhost:11434", # 默认 Ollama API 地址
    }
]

# 2. Executor: DeepSeek-Math-7B (专用数学推理)
deepseek_config_list = {
    "model": "deepseek-chat",
    "api_key": "sk-e685cc8450534eba8a195f44de737be8",
    "base_url": "https://api.deepseek.com",
    "api_type": "openai",
}

# 3. Checker: TinyLlama 1.1b (轻量验证)
tinyllama_config_list = [
    {
        "model": "tinyllama:1.1b",
        "api_type": "ollama",
        "client_host": "http://localhost:11434",
    }
]

# 4. Reflector: Qwen2.5-1.5b (中等规模反思)
qwen_config_list = {
    "model": "qwen2.5-math-1.5b-instruct",
    "api_key": "sk-a9aa08796d7d4f0791d35de9a8ac9b75",
    "base_url": "https://dashscope.aliyuncs.com/compatible-mode/v1",
```

```
"api_type": "openai",
}
```

1.2.2 规划者模块 (Phi-3本地部署)

```
# 规划者 (Phi-3本地部署 - 实际运行输出)
planner = AssistantAgent(
    name="planner",
    llm_config={"config_list": [
        {"model": "phi3:mini", "api_type": "ollama", "client_host":
"http://localhost:11434"}
    ]},
    system_message="""任务分解专家，输出JSON格式任务树。
    用中文回答，当任务完成时返回 'TERMINATE'。"""
)
# 实际运行输出示例：
# "问题: Janet每天有16个鸭蛋... → 分解为: 1. 计算剩余鸭蛋 2. 计算收入"
```

1.2.3 执行者模块 (DeepSeek云端API)

```
# 执行者 (DeepSeek-Math-7B - 实际运行输出)
executor_math = AssistantAgent(
    name="executor_math",
    llm_config={"config_list": [{
        "model": "deepseek-chat",
        "api_key": "sk-e685cc8450534eba8a195f44de737be8",
        "base_url": "https://api.deepseek.com"
    }]},
    system_message="""数学专家，严格执行计算步骤。格式: 步骤解释 -> 结果。
    用中文回答，当任务完成时返回 'TERMINATE'。"""
)
# 实际运行输出：
"""
让我们逐步解决这个问题：
1. 计算每天总产蛋量 -> 16个
2. 减去早餐消耗的鸡蛋 ->  $16 - 3 = 13$ 个
3. 减去用于烘焙松饼的鸡蛋 ->  $13 - 4 = 9$ 个
4. 计算剩余鸡蛋的销售收入 ->  $9 \times \$2 = \$18$ 
因此, Janet每天在农贸市场的收入是$18。
TERMINATE
"""
```

1.2.4 检查者模块 (TinyLlama本地部署)

```
# 检查者 (TinyLlama本地部署)
checker = AssistantAgent(
    name="checker",
    llm_config={
        "config_list": tinyllama_config_list,
    },
    system_message="""请验证以下推理步骤是否正确，用JSON格式回答：\n"
        "{\n  \"valid\": true/false,\n  \"error\": \"错误描述\"\n}\n"
        "推理步骤: {steps}。
        (用中文回答) 当任务完成时，请返回 'TERMINATE'。"""
)
```

1.2.5 反思者模块 (Qwen1.5云端API)

```
# 反思者 (Qwen1.5云端API)
reflector = AssistantAgent(
    name="reflector",
    llm_config={
        "config_list": qwen_config_list
    },
    system_message="""你负责分析错误原因并给出修正建议。(用中文回答)
    当任务完成时，请返回 'TERMINATE'。"""
)
```

1.2.6 协作 workflow 引擎

```
async def solve_problem(question, user_proxy, manager):
    """多智能体协作求解问题 - 实际执行流程"""
    await user_proxy.a_initiate_chat(manager, message=question, max_turns=4)
    final_answer = checker.last_message()["content"]
    return {
        "question": question,
        "answer": final_answer,
        "steps": [msg["content"] for msg in group_chat.messages]
    }

# 实际执行日志摘要:
"""
user_proxy: Janet's ducks lay 16 eggs per day...
executor_math: 1. 计算每天总产蛋量 -> 16个
               2. 减去早餐消耗... -> 13个
               3. ... -> 9个
               4. ... -> $18
checker: 验证推理步骤: {valid: true, error: null}
reflector: Python验证代码: remaining_eggs = 16-3-4; print(9*2) -> 18
"""
```

1.3 轻量模型优化成果

模型	参数量	部署方式		内存占用	实际性能
Phi-3-mini	3.8B	Ollama本地		2.8GB	任务分解准确率较高
TinyLlama	1.1B	Ollama本地		1.2GB	验证速度比Phi-3稍快
DeepSeek-Math	7B	云端API		-	GSM8K准确率78%
Qwen1.5	4B	DashScope API		-	错误分析准确率78%

1.4 评测体系建设

1.4.1 评测指标实现

```
class Evaluator:
    # 实际运行的评测类
    def exact_match(self, pred, gt):
        """精确匹配评分 - 实际测试准确率78%"""
        pred_num = self.ans_re.search(pred).group(1) if self.ans_re.search(pred)
        else None
        gt_num = self.ans_re.search(gt).group(1)
        return int(pred_num == gt_num)

    def stepwise_score(self, pred_steps, gt_steps):
        """分步赋分机制 - GSM8K平均得分85%"""
        matched = 0
        for gt_step in gt_steps:
            if any(gt_step in pred_step for pred_step in pred_steps):
                matched += 1
        return matched / len(gt_steps)
```

1.4.2 GSM8K测试结果（50样本）

模型架构	准确率	分步得分
单一Phi-3	62%	68%
多智能体协作	68%	75%
GPT-4（参考）	92%	94%

1.4.3 性能对比可视化（现在出现一些问题，还在解决过程中）

2. 已完成工作

核心目标完成情况

模块	完成度	主要成果
基础框架	95%	实现四类智能体角色协作架构，实现规划者-执行者-检查者-反思者协作链
模型集成	60%	完成Colab+Xterm环境搭建，Phi-3/TinyLlama/DeepSeek/Qwen部署
任务工作流	40%	完成线性工作流实现
评测系统	50%	实现精确匹配与分步评分机制
数据集测试	30%	现在只完成了对GSM8K数据集数据集的测试

3. 遇到的问题与可能解决方案

3.1 关键技术挑战与解决

问题	可能解决方案	代码实现
异步通信死锁	实现超时重试机制 引入消息优先级队列	<pre>asyncio.wait_for(task, timeout=5)</pre>
模型输出格式不一致	设计统一JSON Schema 格式转换适配层	<pre>json_schema = {"valid": bool, "error": str}</pre>
轻量模型知识局限	动态提示增强 错误回馈学习	<pre>prompt += "\n请特别注意：计算步骤要完整"</pre>
云端API延迟波动	本地缓存+回退机制 请求批处理	<pre>cache = LRUCache(capacity=100)</pre>

3.2 关键问题分析：协作流程中断

问题现象：

```
TypeError: object str can't be used in 'await' expression
File ".../conversable_agent.py", line 2978
    reply = await iostream.input(prompt)
```

根本原因分析：

- 1. Jupyter环境与标准IO流兼容性问题

2. 异步/同步消息处理机制未完全统一
3. 用户代理输入处理未适配Colab环境

4. 下一步计划

核心优化：

1. 完成执行者部分CodeLlama-7B模型的部署以完成代码任务的解决 (06.01-06.07)
2. 完善不同任务动态路由的实现 (06.05-06.10)
3. 完成分支工作流、迭代工作流、自适应该工作流三种工作流模式(06.10-06.15)

评测扩展：

1. 完成对HotpotQA数据集和HumanEval数据集的测试 (06.03-06.08)
2. 修改测评指标可视化模块的代码错误，完善效率指标、过程质量评估等评测指标 (06.08-06.13)
3. 鲁棒性测试套件 (06.12-06.17)

5. 结论

本项目已顺利完成中期目标，构建了完整的四智能体协作框架并在GSM8K数据集上验证了其有效性。关键成果包括：

1. 实现Phi-3(3.8B)+TinyLlama(1.1B)+DeepSeek(7B)的高效协作
2. 在GSM8K上达到68%准确率
3. 开发分步赋分评测系统，过程质量评分达75%

当前瓶颈： 响应时间仍高于GPT-4，资源消耗优化空间较大

下阶段重点：

1. 完成分支工作流、迭代工作流、自适应该工作流三种工作流模式
2. 扩展HotpotQA和HumanEval数据集的评测
3. 实现Docker化部署方案
4. 进一步提升模型性能，提高评测指标
5. 增加更加完整的评测指标，构建多维度评测体系

项目整体按计划推进，预计可按时达成开题设定的各项技术指标，并在轻量模型协作领域形成创新突破。